Bejarano Thomas

Actividad: 4.Métricas para construir árboles de decisión

PEjercicios:
Una empresa desea predecir si un cliente comprará un producto, basándose en ciertos atributos. Se dispone de un conjunto de 10 ejemplos, donde se conoce si cada cliente compró o no compró el producto.

La distribución de la variable objetivo es la siguiente:

- ***5 personas compraron (Sí)***
- ***5 personas no compraron (No)***

Se desea evaluar si el atributo "Edad" es útil para dividir el conjunto de datos y construir un árbol de decisión. Para ello, se divide el conjunto según los valores del atributo "Edad":

- ***Edad = Joven: 4 ejemplos → 3 compraron, 1 no compró***
- ***Edad = Mayor: 6 ejemplos → 2 compraron, 4 no compraron***

Calcular la ganancia de información que se obtiene al dividir el conjunto por el atributo "Edad", siguiendo estos pasos:

1. ***Calcular la entropía del conjunto original.***
2. ***Calcular la entropía de cada subconjunto generado por la división.***
3. ***Calcular la entropía ponderada de la división.***
4. ***Calcular la ganancia de información.***
5. ***Concluir si el atributo "Edad" es útil para dividir el conjunto.***

Resultado esperado

- ***Entropía original =***
- ***Entropía Edad Joven =***
- ***Entropía Edad Mayor =***
- ***Entropía ponderada =***
- ***Ganancia de información =***
- ***Conclusión:***

Respuesta:

1. Entropía original =

P*si* = 5/10 = 0.5

P*no* = 5/10 = 0.5

H(S)= - (0.5 * log2(0.5) + 0.5 * log2(0.5))

= - (0.5 * (-1) + 0.5 * (-1))

= - ((-0.5) + (-0.5))

= - (-1) = 1

2. Entropía Edad Joven =

- Subconjunto Edad = Joven (4 ejemplos: 3 Sí compraron, 1 No compro)

P*si* = *3*/4 = 0.75

P*no* = *1*/4 = 0.25

H(S)= - (0.75 * log2(0.75) + 0.25 * log2(0.25))

= - (0.75 * (-0.415) + 0.25 * (-2))

= - ((-0.311) + (-0.5))

= - (0.811) = 0.811

3. Entropía Edad Mayor =

- Subconjunto Edad = Mayor (6 ejemplos: 2 Sí compraron, 4 No compraron)

P*si* = *2*/6 = 0.33

P*no* = *4*/6 = *0.66*

H(S)= - (0.33 * log2(0.33) + 0.66 * log2(0.66))

= - (0.33 * (-1.599) + 0.66 * (-0.599))

= - ((-0.527) + (-0.395))

= - (0.922) = 0.922

4. Entropía ponderada =
   H*division= 4/10 * 0.811 + 6/10 * 0.922*
   = 0.324 + 0.553 = 0.877

5. Ganancia de información =
   GANANCIA= 1- 877 = 0.123

6. Conclusión =

- El atributo "Edad" es útil para dividir el conjunto de datos porque genera una ganancia de información positiva (0.123), reduciendo la entropía inicial de 1.000 a 0.877. Esto confirma que segmentar a los clientes entre Joven y Mayor ayuda a predecir mejor la decisión de compra.